Tugas Pemrograman 2, Kuliah TBI

Search Engine "from Scratch"

Pada Tugas Pemrograman 2 kali ini, Anda ditugaskan untuk membuat *search engine* dari awal, dengan hanya menggunakan *library* standar pada python, **bukan** *library search engine* siap pakai. Tujuannya adalah agar Anda bisa memahami konsep dan teori yang sudah Anda pelajari sejauh ini ke dalam bentuk implementasi.

Anda tidak mulai dari nol (jadi "nggak *from scratch* banget lah ya")! Anda sudah diberikan kode untuk memulai eksplorasi terkait hal ini. Tugas Anda adalah menggunakan **kreatifitas** Anda untuk memodifikasi dan/atau menambahkan fitur-fitur dari kode yang sudah ada.

Deliverables:

- Di TP2 kali ini, Anda wajib menyimpan kode Anda di **github** Anda masing-masing;
- Anda wajib menuliskan dokumentasi program Anda dalam **Bahasa Inggris** dan menuliskan highlight fitur-fitur penting dan cara *run*/penggunaan dari program Anda;
- Tidak ada yang perlu disubmit ke SCELE. Pengumpulannya adalah dengan kirim email Pak Alfan dan menyampaikan **link ke github** untuk tugas TP2 ini.
- **Deadline: Senin 30 Maret 2026, Pukul 18:00 sore**

* Mengapa kami menyuruh Anda untuk mengerjakan Tugas Pemrograman 2 ini menggunakan github? Kami ingin agar Anda mempunyai portfolio yang baik kektika nanti setelah lulus. Sebagai seorang lulusan Fasilkom UI, isi github Anda sangat berharga dan menentukan karir Anda di masa mendatang. Isilah github kalian dengan proyek-proyek *open source* yang berkualitas dan membanggakan.

Penjelasan Kode Awal yang Diberikan

Secara umum, Anda diberikan:

- 3 buah folder: collection, index, tmp
- 2 buah file *.txt: qrels.txt dan queries.txt
- 6 buah file *.py: bsbi.py, compression.py, evaluation.py, index.py, search.py, util.py

Folder **collection** berisi koleksi dokumen yang akan di-indeks. Sebuah dokumen disimpan sebagai sebuah file teks di folder ini. Nantinya, Anda boleh mengganti isi koleksi yang ada saat ini dengan koleksi lain yang Anda sukai.

Folder **index** awalnya kosong. Nantinya, folder ini akan berisi file biner yang berisi **"inverted index"** dari koleksi dokumen yang ada pada folder **collection**.

Folder **tmp** digunakan saat proses *indexing* untuk menyimpan ***"temporary inverted index"*** sebelum akhirnya digabung menjadi satu ***inverted index*** pada folder **index**.

File **qrels.txt** dan **queries.txt** digunakan untuk melakukan evaluasi kualitas efektivitas dari *search engine* yang sudah dikembangkan. File **qrels.txt** berisi daftar ID *query* dan juga ID dokumen yang diketahui **relevan**. Sekedar informasi, informasi relevansi ini diberikan oleh annotator manuasia. Kemudian, file **queries.txt** berisi daftar 30 *query* yang digunakan untuk menguji *search engine* Anda.

Sisanya adalah file *.py yang menjadi jantung dari *search engine* kita. **Setiap file sudah diberikan dokumentasi yang jelas untuk setiap method/fungsi yang ada**. Berikut adalah diagram kebergantungan antar modul python tersebut.

```
index.py ---------------
                        \
                     --- bsbi.py-----
                    /    /           \
util.py--------------    /             -----------------
                        /              | evaluation.py |
                       /               | search.py     |
                      /                -----------------
                     /                 /
compression.py ------------------------
```

File **bsbi.py** berisi abstraksi **Inverted Index** dan juga logika untuk melakukan indexing dengan skema **BSBI** (**blocked-sort based indexing**). File **index.py** berisi logika dasar untuk menulis dan membaca indeks pada **bsbi.py**.

File **util.py** berisi utilitas dasar untuk melakukan indexing, seperti class **IdMap** untuk melakukan mapping dokumen dan term ke sebuah integer. Ingat bahwa dengan skema BSBI, kita perlu mengelola struktur data untuk *mapping* Term-Term ID. Di file **util.py**, ada juga fungsi yang berguna untuk melakukan *merging* atau penggabungan hasil dari dua buah *postings lists*.

File **compression.py** berisi kebutuhan untuk melakukan *index compression*. Saat ini, baru ada metode **Variable Byte Encoding** (VBE).

File **search.py** memberikan contoh bagaimana melakukan proses pencarian diberikan beberapa **query**. Perhatikan bahwa inverted index terlebih dahulu, sebelum **search.py** dieksekusi.

File **evaluation.py** digunakan untuk melakukan evaluasi seberapa efektif search engine Anda diberikan query relevance judgment (**qrels.txt**) dan daftar *query* yang cukup banyak (30 *query*) pada **queries.txt**. Di dalamnya juga ada implementasi sebuah metric, yaitu **Rank-Biased Precision (RBP)**.

Cara menjalankan:

1. Jangan lupa melakukan indexing terlebih dahulu dengan melakukan run **bsbi.py**
2. Silakan coba melakan retrieval untuk beberapa query, dengan menjalankan **search.py**
3. Jika Anda penasaran dengan kualitas search engine Anda, silakan run **evaluation.py** dan lihat skor RBP-nya.

Tugas Anda (100 Point):

1. [30 Point] Tambahkan **satu** algoritma kompresi lain selain VBE, tetapi harus yang bersifat **Bit-Level** seperti Elias-Gamma, OptPForDelta, **atau** yang lainnya.
2. [30 Point] Tambahkan fungsionalitas bisa melakukan *scoring* dengan **BM25**. Saat ini, hanya bisa menggunakan TF-IDF biasa. Untuk menambahkan fungsionalitas **BM25**, Anda perlu melakukan pre-komputasi untuk panjang dokumen dan juga rataan panjang dokumen saat *indexing* dan disimpan di suatu struktur data.
3. [30 Point] Tambahkan **tiga** metrik evaluasi lain: **NDCG**, **DCG**, dan **AP**.
4. [10 Point] Tambahkan algoritma **WAND Top-K Retrieval** agar tidak semua dokumen dihitung skor **BM25**-nya. Anda perlu edit dan sesuaikan isi dari *Inverted Index*-nya.

Bonus (150 Point) !

Ya, jika Anda mengerjakan tugas utama (100 Point) dan mendapatkan nilai penuh untuk Bonus (150 Point), Anda akan mendapatkan total 250 Point untuk Tugas Pemrograman 2 ini. Perhatikan juga bahwa persentase Tugas Pemrograman 2 aslinya adalah 4%, yaitu normalnya berkontribusi sebesar 4 Point untuk nilai akhir. Namun, jika Anda mendapatkan full 250 Point, Anda akan memperoleh full 10 Point ke nilai akhir kuliah TBI ini. **Jadi, jangan sampai Anda tidak memanfaatkan kesempatan ini.**

Bonus ini diberikan kepada peserta yang merasa tidak puas dengan Empat fitur utama yang sudah dibahas sebelumnya, dan merasa ingin membuat *search engine* yang bisa mendekati *library search engine* yang available di Internet, seperti:

- https://pyterrier.readthedocs.io/en/latest/
    - (https://github.com/terrier-org/pyterrier)
- https://github.com/castorini/pyserini
- Dsb.

Penilaian bonus akan didasarkan kepada usaha yang diberikan oleh peserta untuk mengimplementasikan fitur-fitur tambahan lain, seperti:

1. Ada mode indexing dengan **SPIMI**, daripada **BSBI**;
2. *Term-term* pada *dictionary* disusun menggunakan struktur data yang lebih kompleks dan efisien seperti **TRIE**, **Patricia Tree**, atau **Finite State Transducer** (FST);

3. Ada opsi untuk melakukan *Latent Semantic Indexing* dengan vektor-vektor dokumen di-index menggunakan Teknik *Vector Indexing* seperti **FAISS** (https://github.com/facebookresearch/faiss). Namun, Anda harus memikirkan bagaimana melakukan SVD yang efisien melibatkan *Term-Document Matrix* yang sangat besar. Terkait *Vector Indexing*, Anda akan belajar di kelas nanti.
4. Adaptive Retrieval: https://pyterrier.readthedocs.io/en/latest/ext/pyterrier-adaptive/index.html
5. Dan fitur-fitur menarik lainnya …